

프로젝트 기획서

오픈소스 LLM · RAG 기반 PDF 양식 자동 작성 시스템

빈 양식 + 컨셉 입력만으로 완성 문서를 생성하는 지능형 문서 작성 어시스턴트

팀명	똑딱 (TookTak)
팀원 및 역할	팀장 김세경 / 팀원 채요한, 박은선, 이권형
주제 구분	기업과제 (PBL)
기업명 / 멘토명	엑시오 / 김전일
아이디어 주제	오픈소스 LLM과 RAG 기반 PDF 양식 자동 작성 시스템 개발
문서 버전	v3.0 (시각자료·근거 보강)

목 차

1. 팀 구성 및 역할 분담
2. 제안 배경 및 필요성
3. 문제 정의 및 목표
4. 유사 제품 현황 및 비교
5. 차별화 전략
6. 시스템 아키텍처
7. 기술 스택 및 모델 선정
8. 개발 범위 (MVP / 중장기 분리)
9. 데이터 확보 및 전처리
10. 추진 일정 (WBS)
11. 평가·검증 계획
12. 리스크 관리
13. 기대효과 및 활용방안
14. 참고자료

1. 팀 구성 및 역할 분담

팀원은 5개월 코딩 교육을 수료한 훈련생으로 구성됨. 본 PBL은 주니어 개발자가 4주 내 완수 가능한 범위를 기준으로 역할을 분담함.

역할 분담 (R&R, 협의 후 조정 가능)

팀원	담당 모듈	주요 책임
김세경 (팀장)	총괄·통합·프론트엔드	일정 관리, 시스템 통합, 웹 대시보드(UI) 구현, 데모 시연
채요한	PDF 파싱·폼필드 추출	PyMuPDF 기반 AcroForm 필드/좌표 추출, 메타데이터 정형화
박은선	RAG 파이프라인	칭킹·임베딩·벡터 저장(ChromaDB)·top-k 검색 구현
이권형	LLM 서빙·백엔드	Ollama 모델 서빙, FastAPI 엔드포인트, PDF 데이터 주입


협업 및 형상관리

- Git 기반 형상관리(브랜치 전략: main/feature), 주 2 회 진행 점검 회의, 이슈 트래커로 작업 단위 관리. 모듈 경계(인터페이스)를 먼저 합의한 뒤 병렬 개발함.

2. 제안 배경 및 필요성

1) 생성형 AI 도입 가속

국내 749개 기업 조사 결과 55.7%가 생성형 AI를 전사(22.4%) 또는 일부 부서(33.2%)에서 활용 중이며, 2026년에는 활용 기업이 85%를 넘어설 전망이다. 활용 목적 1위는 업무 효율성·생산성 향상(70.5%)임.



[그림 2-1] 국내 기업 생성형 AI 활용 현황 및 2026년 전망

관련 기사 발췌

메가존클라우드·Foundry가 국내 기업 AI-IT 담당자 749명을 조사한 결과, 절반 이상이 이미 생성형 AI를 도입했고


1~2년 내 도입 계획까지 포함하면 2026년에는 활용 기업이 85%를 넘어설 것으로 전망됨. 대표적 활용 업무는 문서 요약·보고서 작성(43.1%)으로, 정형 문서 자동화 수요가 가장 큼.

— CIO Korea · 디지털경제뉴스, '2026년 국내 기업 85%가 생성형 AI 도입' (2025)

2) 보안 우려의 심화

도입 확대와 동시에 보안 우려도 커지고 있음. 국내 IT·보안 실무자 667명 조사에서 'AI 기반 보안 위협'이 2026년 최대 위협 1위(81.2%)로 꼽혔으며, 생성형 AI 활용 기업의 주요 우려로 결과 신뢰도 부족(61.3%)과 보안·개인정보 유출(53.3%)이 지목됨.

도입 확대와 함께 커지는 보안·신뢰도 우려



출처 : 삼성SDS '2026년 5대 사이버 보안 위협'(667명) · 메가존클라우드·Foundry 조사 (2025~2026)

[그림 2-2] 보안·신뢰도 우려 지표


3) 온프레미스 전환 흐름

외부 상용 API(ChatGPT 등) 사용 시 사내 기밀·건적·개인정보가 외부 서버로 전송되는 리스크가 상존함. 이에 기업 추론을 자체 인프라에서 수행하는 비중이 2023년 12%에서 2025년 55%로 4.6배 증가함. 로컬 오픈웨이트 모델은 토큰당 비용이 상용 API 대비 최대 18배 저렴한 것으로 보고됨.

온프레미스·로컬 LLM 전환 흐름

규제 산업 중심 확산

기업 자체 인프라(온프레미스) 추론 비중
55%



· 2025년 온프레미스 배포가 전체 시장의 약 52% 차지

로컬 배포의 핵심 이점

18배

토큰당 비용 절감
(상용 API 대비, 로컬 오픈웨이트)

97%

응답 지연 감소
(1.5초 → 약 40ms)

70%

기업이 내부 LLM 우선
(보안 우려가 전환 견인)

1,225%

4년 누적 ROI
(자체 AI 인프라 투자 기준)

출처 : On-Premise LLM Deployment Statistics (DreamFactory / TrueFoundry, 2025~2026)

[그림 2-3] 온프레미스·로컬 LLM 전환 지표

관련 기사 발췌

규제 산업(은행·병원·공공기관)을 중심으로 온프레미스 추론이 2025년 배포 시장의 절반 이상을 차지함. 로컬 배포는 응답 지연을 크게 줄이고 토큰당 비용을 상용 API 대비 최대 18배 낮추며, 데이터가 조직 외부로 나가지 않아 규제 준수에 유리한 것으로 분석됨.

— On-Premise LLM Deployment Statistics (DreamFactory / TrueFoundry, 2025~2026)

4) 필요성 요약

- 외부 API 의존을 제거한 온프레미스 LLM 에 사내 문서만 참조하는 RAG 를 결합하면, 환각을 제어하고 데이터 주권을 확보하면서 정형 문서 작성 생산성을 높일 수 있음. 본 프로젝트는 이 두 목표를 동시에 달성하는 PDF 양식 자동 작성 어시스턴트를 개발함.

3. 문제 정의 및 목표

해결할 문제

- 정형 양식(견적서·신청서·보고서 등) 작성에 반복적·수작업 행정 시간이 소요됨.
- 상용 AI 서비스는 사내 데이터 외부 유출 위험으로 도입이 제약됨.
- 기존 도구는 문서 요약·Q&A 중심이며, 빈 양식을 인식해 채우는 자동화가 미비함.

목표 (정량 KPI)

MVP는 4주 일정·주니어 팀 역량을 고려해 보수적으로 설정함. 70% 단축 등 공격적 목표는 중장기 지표로 분리함.

지표	MVP 목표 (이번 PBL)	중장기 목표
지원 양식 종류	2종 이상 (AcroForm)	임의 평면 PDF 포함 다종
폼필드 자동 채움 정확도	≥ 80% (필드 매칭률)	≥ 95%
문서 1건 작성 시간 단축	≥ 50% (수작업 대비)	≥ 70%
외부 API 호출 건수	0건 (완전 로컬)	0건 유지
추론 환경	단일 GPU/CPU, 소형 모델	양자화·다중 GPU 서빙

정확도·시간단축 측정 방법은 11. 평가 검증 계획에서 정의함.

4. 유사 제품 현황 및 비교

구분	ChatGPT Plus	MS Copilot Pro	Adobe Acrobat AI	본 시스템(똑딱)
주요 기능	파일 업로드 분석, 다목적 초안 생성	Office 365 연동, 사내 인덱스 검색	PDF 요약·대화형 Q&A, 출처 하이라이팅	빈 양식 인식 후 항목 자동 채움·생성
장점	범용 LLM 추론 성능, 다양한 포맷 인식	오피스 생태계 통합, 엔터프라이즈 보안	원본 레이아웃 파싱 정확, 뷰어 내장	온프레미스 완전 로컬, 좌표 기반 정밀 주입
단점	데이터 외부 유출, 폼필드 좌표 주입 부재	추가 라이선스 비용, 오픈소스 커스텀 제약	읽기·요약 중심, 양식 자동 채움 미비	초기 구축·서빙 부담 (중장기 자동화로 보완)

구분	ChatGPT Plus	MS Copilot Pro	Adobe Acrobat AI	본 시스템(똑딱)
데이터 보안	외부 전송	클라우드 의존	클라우드 의존	사내 폐쇄망 (유출 0)

핵심 차별점: 외부 전송 없는 온프레미스 환경에서 '빈 양식 → 완성 문서' 자동화를 제공하는 점.

5. 차별화 전략

네 가지 핵심 축으로 경쟁 도구와 차별화함. 각 축은 MVP에서 안정적으로 구현하고, 고도화 항목은 모듈 인터페이스를 유지한 채 중장기로 확장함.

차별화 축	MVP 적용	중장기 확장
정밀 양식 분석	PyMuPDF·pdfplumber 이중 엔진으로 폼필드·표 구조·좌표(x,y)를 전수 추출·정형화, 장식 테두리·로고 오차는 LLM 후처리로 제거	멀티모달(Vision) 양식 인식, 표 셀 자동 맞춤
환각 제어 RAG	사내 문서만 참조하는 top-k 단일 검색으로 근거 기반 데이터 추출	하이브리드 검색(BM25+벡터, RRF) + 리랭킹(cross-encoder)
좌표 정밀 주입	AcroForm 위젯에 한글 폰트 깨짐 없이 자동 줄바꿈·셀 맞춤으로 채움	평면(비 AcroForm) PDF 좌표 오버레이 주입
데이터 주권	외부 API 의존 제거, 폐쇄형 온프레미스(외부 호출 0)	금융·의료·공공 등 규제 산업 B2B 패키지화

환각 제어 RAG 동작 원리

환각 제어 RAG 파이프라인

사내 문서만 참조해 근거 기반으로 값을 생성 — 검색 단계를 MVP에서 단순화하고 중장기에 고도화함

① 인덱싱 (오프라인 준비)



② 질의 시 검색 → 생성



왜 환각이 줄어드는가

- 검색된 근거 컨텍스트 안에서만 값을 생성하도록 제약 — 모델이 임의로 지어내는 여지를 차단함
- 업계 보고 기준, 하이브리드 검색+리랭킹 적용 시 환각률을 큰 폭(보고에 따라 40% 이상)으로 낮추는 것으로 알려짐

[그림 5-1] 환각 제어 RAG 파이프라인 (MVP 단일 검색 → 중장기 2단계 고도화)

6. 시스템 아키텍처

처리 흐름 (End-to-End)

End-to-End 처리 흐름

빈 양식 업로드부터 완성 문서 다운로드까지 — 전 구간 사내 폐쇄망에서 동작




✓ 외부 네트워크 호출 0건 — 사내 기밀·개인정보가 외부 서버로 전송되지 않는 완전 로컬 구조

[그림 6-1] End-to-End 처리 흐름

레이어 구성

레이어 구성 — 계층형 아키텍처

I/O · 비즈니스 로직 · 영속화를 분리하고 모듈 간 의존은 순환 없는 단방향(DAG)으로 유지함



[그림 6-2] 계층형 시스템 아키텍처

계층 분리 원칙

- I/O(업로드·DB·파일), 비즈니스 로직(파싱·RAG·생성), 영속화(벡터 DB·메타 DB)를 서로 다른 모듈로 분리하고, 모듈 간 의존은 순환 없는 단방향(DAG)으로 유지함.

7. 기술 스택 및 모델 선정

기술 스택

영역	기술	선정 사유
백엔드	Python 3.13 / FastAPI	비동기 처리, 타입 힌트, 빠른 API 개발
프론트엔드	React	컴포넌트 기반 미리보기·대시보드 UI

영역	기술	선정 사유
PDF 처리	PyMuPDF(fitz) + pdfplumber	폼필드·좌표 추출 정확도, 이중 엔진 보완
PDF 주입	pypdf / ReportLab	AcroForm 채움 및 좌표 오버레이
벡터 DB	ChromaDB	경량·로컬 구동, 주니어 친화적 API
LLM 서빙	Ollama	설치·운영 단순, 양자화 모델 즉시 구동
RAG 프레임워크	LangChain	파이프라인 구성요소 풍부, 예제·문서 다수

버전은 매니페스트에 정확히 고정하고 lock 파일을 형상관리에 포함함(의존성 정책).

오픈소스 LLM 비교 및 선정

모델	라이선스	한국어	소형 모델 VRAM(Q4)	비고
Qwen3 8B	Apache-2.0	양호	약 6~7GB	상업 이용 자유, 화이트리스트 적합
EXAONE 4.0	비상업(NC)	우수	1.2B/32B 등	연구·교육만, 상업화 별도 계약
Llama 3.x 8B	Llama Community	보통	약 5~7GB	별도 커뮤니티 라이선스 검토 필요

- 선정 : MVP·향후 사업화를 고려해 Apache-2.0 인 Qwen3 8B(Q4_K_M, 약 6~7GB)를 주력으로 채택함. EXAONE 는 한국어 성능이 우수하나 비상업 라이선스이므로 연구·검증 단계에서만 비교 평가하고, 상업 배포 시에는 사용하지 않음.

관련 동향·근거

- 삼성 SDS, '2026 년 5 대 사이버 보안 위협' — AI 기반 위협 1 위(81.2%, 667 명)
- 메가존클라우드·Foundry — 국내 749 개사 생성형 AI 활용률 55.7%, 2026 년 85% 전망
- RAG 운영 정설(2025) : 하이브리드 검색(BM25+벡터, RRF) + 리랭킹이 정확도 핵심 — 증장기 적용
- PyMuPDF 폼 채움·평탄화, pdfplumber 폴백 이중 엔진 + LLM 오답 제거 기법(2025~2026)
- EXAONE 4.0 : EXAONE AI Model License 1.2-NC (비상업)

8. 개발 범위 (MVP / 증장기 분리)

본 PBL에서 구현 가능한 MVP 범위와, 이후 단계적으로 업그레이드할 증장기 범위를 분리함. MVP는 4주 일정·주니어 역량 기준으로 안정적 동작에 집중함.

MVP 범위 (이번 PBL, 4 주)

모듈	MVP 구현 내용	산출물
PDF 파싱	AcroForm 폼필드·라벨·좌표 추출, 메타데이터 JSON 정형화	필드 스키마 추출기
RAG	칭킹·임베딩·ChromaDB 저장·top-k 검색 (단일 검색)	검색 모듈 + 인덱스

모듈	MVP 구현 내용	산출물
LLM 생성	Ollama로 Qwen3 8B 서버, 필드별 값 생성·후처리	생성 서비스 API
주입	AcroForm 위젯에 한글 폰트로 값 채움·평탄화	PDF 채움 엔진
웹 UI	양식 업로드 → 컨셉 입력 → 생성 → 미리보기 → 다운로드	단일 대시보드
배포	로컬 실행 가이드 (Docker 선택)	실행 문서

- 지원 양식은 2 종(예: 견적서, 간단 신청서)으로 한정해 완성도를 확보함.

중장기 범위 (PBL 이후 업그레이드)

단계	확장 내용
Phase 2	평면(비 AcroForm) PDF 좌표 오버레이 주입, 표 셀 자동 맞춤
Phase 2	하이브리드 검색(BM25+벡터, RRF) + 리랭킹(cross-encoder)으로 정확도 향상
Phase 2	다중 쿼리 확장, 프롬프트 템플릿 고도화, 평가 하베스트 자동화
Phase 3	vLLM 서버·양자화 튜닝, 대형 모델 전환, 다중 GPU 확장
Phase 3	멀티모달(Vision) 양식 인식, 기업별 맞춤 프롬프트·에이전트
Phase 3	프롬프트 인젝션 방어 등 보안 강화, B2B 패키지화·사업화

중장기 항목은 MVP의 모듈 인터페이스를 유지한 채 교체·증설하는 방식으로 확장함.

9. 데이터 확보 및 전처리

데이터 확보 방안

구분	내용	비고
표준 양식	행정·비즈니스 표준 PDF 양식(견적서·신청서 등) 수집	라이선스·재배포 조건 확인
도메인 지식	공공 오픈 데이터셋(AI Hub 등) 및 가이드라인 활용	출처·라이선스 명시
벡터 인덱스	청킹 데이터 임베딩 후 ChromaDB 저장	RAG 검색 대상

전처리 절차


- 텍스트 정제 : 머리말·꼬리말·페이지 번호 등 노이즈 제거.
- 무효 임베딩 제거 : 빈 청크·중복 청크 필터링.
- 필드 오답 제거 : 장식 테두리·로고·안내문에 잡힌 필드를 규칙 + LLM 검증으로 제거.
- 개인정보·기밀 점검 : 학습/인덱싱 데이터에 민감정보 미포함 확인.

10. 추진 일정 (WBS)

명목 6주 일정이나 실질 가용 기간 약 4주를 기준으로, 핵심 경로(파싱→RAG→주입→UI)에 우선순위를 둬. 1~2주차 설계는 압축 병행함.

추진 일정 (WBS) — 실질 가용 약 4주

핵심 경로(파싱 → RAG → 주입 → UI)에 우선순위를 두고 1~2주차 설계는 압축 병행함



· 주차별 '최소 동작 산출물'을 정의 — 지연 시 고도화 항목(리랭킹·평면 PDF 주입 등)을 즉시 중장기로 이관(범위 보호)

[그림 10-1] 주차별 WBS 간트차트

주차	핵심 작업	담당	산출물·마일스톤
1주차	요구사항 분석, 대상 양식 2종 선정, 입력 스키마·아키텍처 설계	전원	설계서, 인터페이스 정의
2주차	PDF 파서(AcroForm) 구현, RAG 기초(청킹·임베딩·검색) 구축	채요한·박은선	파서 + 검색 모듈
3주차	Ollama LLM 서버·생성 로직, PDF 주입 엔진 구현	이권형	생성·주입 동작
3~4주차	웹 대시보드 연동, End-to-End 통합	김세경	통합 데모
4주차	통합 테스트, 평가(KPI 측정), 데모 시나리오 검증·발표 준비	전원	최종 산출물·발표

Docker 배포·문서화는 여유 시 4주차에 포함, 미달 시 중장기로 이관함(범위 보호).

일정 리스크 완충

- 주차별 '최소 동작 산출물'을 정의해, 일정 지연 시 고도화 항목(리랭킹·평면 PDF 주입 등)을 중장기로 즉시 이관할 수 있도록 범위를 설계함.


11. 평가·검증 계획

3. 목표의 KPI를 측정 가능한 프로토콜로 정의함. 모든 측정은 동일 양식·동일 입력 세트로 반복해 재현성을 확보함.


MVP 정량 목표 (KPI) — 합격 기준



폼필드 자동 채움
정확도 (필드 매칭률)



문서 작성 시간
단축 (수작업 대비)



환각·근거
일치율



외부 API
호출 (완전 로컬)

· 모든 측정은 동일 양식·동일 입력 세트로 반복해 재현성 확보 — 측정 프로토콜은 '11. 평가·검증 계획' 참조

[그림 11-1] MVP 정량 목표(KPI) 합격 기준

KPI	측정 방법	합격 기준(MVP)
폼필드 자동 채움 정확도	정답 라벨이 있는 양식 N건에 대해 (정확 채움 필드 / 전체 필드) 평균	≥ 80%
문서 작성 시간 단축	동일 문서를 수작업 vs 시스템으로 작성한 소요시간 비교 (1 - 시스템/수작업)	≥ 50%
환각·근거 일치율	생성 값이 RAG 검색 근거에 존재하는지 표본 검수 비율	≥ 90%
보안(외부 호출 0)	네트워크 트래픽 모니터링으로 외부 도메인 호출 0건 확인	0건

테스트 전략

- 단위 테스트: 파싱·칭킹·주입 등 로직을 외부 의존성 모킹으로 검증.
- 통합 테스트: 업로드→생성→다운로드 전 구간을 실제 모듈로 검증.
- 회귀 테스트: 버그 발견 시 재현 테스트를 먼저 추가한 뒤 수정.

12. 리스크 관리

리스크	영향	대응책
주니어 팀의 기술 난이도 (서빙·RAG)	일정 지연	MVP 범위 축소·Ollama 등 단순 도구 채택, 멘토 점검
로컬 GPU 자원 부족	추론 지연·실패	Qwen3 8B Q4 등 소형 양자화 모델, CPU 폴백 경로 확보
다양한 양식 구조 편차	주입 실패	MVP는 AcroForm 2종으로 한정, 평면 PDF는 중장기 이관
환각·오채움	문서 신뢰도 저하	RAG 근거 기반 생성 + 미리보기 사용자 확인 단계
데이터 라이선스·민감정보	법적·보안 리스크	출처·라이선스 점검, 민감정보 필터링, 비밀정보 비저장
모델 라이선스(EXAONE NC)	상업화 제약	상업 배포는 Apache-2.0 모델 사용, EXAONE는 연구용 한정

13. 기대효과 및 활용방안

기대효과

- 업무 생산성 향상: 정형 문서 작성 시간을 MVP 50%(중장기 70%) 단축해 핵심 업무 집중.
- 데이터 보안 확보: 외부 API 미사용·완전 코일 구조로 기밀 데이터 유출 원천 차단.
- 인프라 비용 절감: 양자화 오픈소스 모델로 상용 API 호출 비용 대비 운영비 최소화.
- 실용 AI 역량 내재화: 파싱·RAG·서빙·주입까지 연동한 LLM 애플리케이션 개발 역량 확보.

활용방안

- 정부지원사업·공공 문서: 규격이 까다로운 신청서·사업계획서 초안 자동 완성.
- 기업 내 표준 문서 자동화: 견적서·회의록·주간/월간 보고서 등 반복 서식.
- B2B 엔터프라이즈: 금융·의료·공공·제조 등 보안 민감 산업의 프라이빗 문서 자동화 패키지.

14. 참고자료

-
- [1] 삼성SDS, '2026년 5대 사이버 보안 위협' 발표 (보안뉴스, 2026)
<https://m.boannews.com/html/detail.html?mtype=1&idx=142338>
 - [2] 삼성SDS 인사이트리포트, '2026년 사이버 보안 위협 트렌드 전망 및 대응'
<https://www.samsungds.com/kr/insights/cybersecurity-threats-and-response-2026.html>
 - [3] 메가존클라우드·Foundry, '2025년 국내 기업 생성형 AI 활용 현황 및 전망' (디지털경제뉴스)
<http://www.denews.co.kr/news/articleView.html?idxno=33506>
 - [4] On-Premise LLM Deployment Statistics (DreamFactory, 2025)
<https://www.dreamfactory.com/hub/on-premise-llm-deployment-statistics>
 - [5] Optimizing RAG with Hybrid Search & Reranking (Superlinked VectorHub)
<https://superlinked.com/vectorhub/articles/optimizing-rag-with-hybrid-search-reranking>
 - [6] Automating PDF Form Filling and Flattening with PyMuPDF (Artifex)
<https://artifex.com/blog/automating-pdf-form-filling-and-flattening-with-pymupdf>
 - [7] Best Open Source LLM for Korean in 2026 (SiliconFlow)
<https://www.siliconflow.com/articles/en/best-open-source-llm-for-korean>
 - [8] LGAI-EXAONE/EXAONE-4.0-32B Model Card (Hugging Face, License 1.2-NC)
<https://huggingface.co/LGAI-EXAONE/EXAONE-4.0-32B>
 - [9] Qwen3 Hardware Requirements / VRAM Guide (2026)
<https://llmhardware.io/guides/qwen3-hardware-requirements>

수치·기술 동향은 위 외부 출처에 근거함. 접속 시점에 따라 URL이 변동될 수 있음.